

Sensibilidade aos protocolos de avaliação e à engenharia de atributos na classificação de intrusões em UAVIDS-2025

Versão para revisão dos autores — 27 de setembro de 2026

Autores, afiliações, ORCID e autor correspondente: preencher antes da submissão.

Resumo

Estimativas de desempenho em benchmarks de detecção de intrusões dependem da população de teste e das transformações aplicadas aos atributos. Este estudo avalia essas escolhas no UAVIDS-2025, um conjunto simulado com 122.171 fluxos e cinco classes. Random Forest e XGBoost foram comparados em três protocolos de validação cruzada: divisão aleatória estratificada, separação de assinaturas numéricas idênticas e separação por endereço de origem. Identificadores de fluxo e endereços foram excluídos dos preditores. Uma ablação pareada avaliou três razões derivadas, isoladamente e em conjunto, com parâmetros fixos e imputação ajustada apenas no treinamento. No tratamento de referência, com os 18 atributos originais, o F1-macro do XGBoost foi 0,956326 na divisão aleatória e 0,952666 na separação por origem. Nesta última, os oito intervalos condicionais das diferenças entre os tratamentos derivados e o painel de referência incluíram zero. A razão entre pacotes perdidos e transmitidos foi quase redundante com a taxa de descarte fornecida, e a razão de vazão por salto ficou indefinida em 38.501 registros. Uma repetição com três inicializações e uma análise de sensibilidade ao recorte da taxa de descarte não sustentaram ganho geral das transformações. No benchmark em contêiner Linux limitado a 0,5 CPU e 512 MiB, XGBoost teve mediana HTTP de 1,107 ms; entre os quatro modelos medidos, as medianas variaram de 0,912 a 5,856 ms. As conclusões se restringem à classificação de vetores de fluxo e ao custo local observado neste benchmark.

Palavras-chave: UAV; detecção de intrusões; avaliação por grupos; ablação de atributos; reprodutibilidade.

Abstract

Performance estimates in intrusion-detection benchmarks depend on the test population and feature transformations. We evaluated these choices in UAVIDS-2025, a simulated dataset containing 122,171 flows and five classes. Random Forest and XGBoost were compared under stratified random folds, disjoint exact numeric signatures, and disjoint source addresses. Flow identifiers and addresses were excluded from the predictors. A paired ablation assessed three derived ratios, individually and jointly, with fixed parameters and training-only imputation. With the 18 original features, XGBoost macro F1 was 0.956326 under random splitting and 0.952666 under source-disjoint evaluation. In the latter protocol, all eight conditional intervals for differences between derived treatments and the original-feature reference included zero. The packet-loss ratio was nearly redundant with the supplied packet-drop rate,

and throughput per hop was undefined in 38,501 records. A three-initialization repetition and packet-drop-rate clipping sensitivity did not support a general improvement. In a Linux container limited to 0.5 CPU and 512 MiB, XGBoost achieved a 1.107 ms median HTTP latency; across the four measured models, medians ranged from 0.912 to 5.856 ms. The findings are restricted to flow-vector classification and local inference cost in this benchmark.

Keywords: UAV; intrusion detection; grouped evaluation; feature ablation; reproducibility.

1. Introdução

Conjuntos públicos de dados permitem comparar classificadores de intrusões, mas a interpretação de suas métricas exige descrever o que o conjunto de teste representa. Fluxos diferentes podem compartilhar endereços, condições de geração e vetores de atributos idênticos. Uma divisão aleatória avalia a classificação de registros retirados da mesma coleção; ela não estabelece, por si só, desempenho diante de uma nova campanha de simulação ou de uma rede operacional.

O UVIDS-2025 disponibiliza registros de tráfego normal e de quatro ataques em redes de veículos aéreos não tripulados (UAVs) [1,2]. Seu benchmark original e trabalhos subsequentes já estudaram classificadores de árvores, ensembles, redes neurais e interpretação de erros [1,3]. Portanto, obter F1 elevado com Random Forest ou XGBoost não constitui contribuição suficiente. Também não é inédita a preocupação com identificadores e separação por origem: ela foi explorada em uma tarefa de detecção de Sybil desconhecido, com representação de taxas por origem [4].

Este trabalho aborda duas perguntas delimitadas. Primeiro, quanto o desempenho da classificação fechada de cinco classes muda entre divisões aleatórias, divisões que impedem assinaturas numéricas idênticas nos dois lados e divisões por origem? Segundo, três razões de contadores de fluxo acrescentam ganho consistente aos mesmos modelos e partições? O interesse está na comparação controlada, incluindo resultados negativos, e na interpretação das limitações dos atributos disponíveis.

As contribuições são a caracterização dos dados e das transformações propostas, a comparação pareada dos protocolos e dos tratamentos de atributos, e a análise dos limites de inferência. Como os dados e resultados anteriores já haviam sido examinados, as análises são exploratórias.

2. Trabalhos relacionados

Zeng, Bashir e Nait-Abdesselam apresentam o UVIDS-2025 e um benchmark com divisão estratificada de treinamento e teste [1]. O registro público descreve simulação com NS-3.24, mobilidade BOID, IEEE 802.11ac, roteamento AODV e propagação Nakagami. A disponibilização do CSV favorece estudos posteriores; entretanto, o arquivo utilizado aqui não contém identificadores de execuções nem código de coleta que permita reconstruir cenários independentes.

Zarkadis e Douligeris avaliam ensembles e modelos neurais, seleção de atributos e explicações SHAP no mesmo conjunto de dados [3]. Entre os erros discutidos estão as confusões entre Blackhole e Wormhole, também examinadas neste estudo. O foco complementar é comparar três populações de teste e verificar transformações de atributos sob um controle comum. A divisão e o pré-processamento daquele trabalho diferem dos empregados aqui, inviabilizando uma ordenação direta dos respectivos valores de F1.

Demir e Gümüş estudam detecção de Sybil desconhecido com separação por origem e exclusão de valores brutos de identificadores [4]. Sua tarefa deixa uma classe de ataque fora do ajuste e utiliza medidas de detecção de novidade. Aqui todas as cinco classes estão presentes no treinamento e no teste.

Assim, diferenças de métricas não indicam superioridade entre os trabalhos; o estudo anterior também impede tratar o simples uso de origens disjuntas como contribuição inédita.

Islam et al. avaliam ensembles explicáveis em conjuntos de drones e de redes industriais [5]. Na tarefa descrita para UVIDS-2025, as classes são mapeadas para Normal, Blackhole e Wormhole. Esse mapeamento difere das cinco classes preservadas neste artigo. A literatura selecionada contextualiza a pergunta e suas limitações; não constitui uma revisão sistemática, nem permite afirmar que o presente protocolo supera todos os trabalhos anteriores.

3. Dados e métodos

3.1. Conjunto de dados e tarefa

Foi utilizado o UVIDS-2025, disponibilizado no Zenodo (DOI 10.5281/zenodo.15336998) sob licença CC BY 4.0 [2]. O arquivo contém 122.171 fluxos e 23 colunas, com 176 endereços de origem e 218 de destino distintos. Não há correspondência verificável entre os endereços e aeronaves físicas. As fórmulas exatas de coleta, as janelas de observação e o instante de disponibilidade de cada atributo não foram reconstruídos. Por isso, a tarefa foi descrita como classificação de vetores de fluxo disponíveis no arquivo.

A tarefa supervisionada atribui a cada vetor uma das cinco classes originais, sem introduzir ataques desconhecidos ou alterar os rótulos. A Tabela 1 apresenta os suportes de classe, preservados na agregação das predições fora da amostra.

Tabela 1. Composição do conjunto de dados e suporte das classes.

Classe	Fluxos
Normal Traffic	26.172
Blackhole Attack	26.110
Flooding Attack	19.726

Classe	Fluxos
Sybil Attack	24.077
Wormhole Attack	26.086

Fonte: análises do estudo com UAVIDS-2025 [2].

3.2. Protocolos de avaliação

Foram comparados três protocolos de validação cruzada com cinco partições: divisão aleatória estratificada, separação por assinatura numérica e separação por endereço de origem. Em cada partição, quatro quintos dos registros foram usados para treinamento e o quinto restante para avaliação. A divisão aleatória preserva aproximadamente as proporções das classes. Na separação por assinatura, registros com valores idênticos nos 18 atributos originais permanecem no mesmo grupo. Na separação por origem, todos os fluxos associados ao mesmo endereço de origem permanecem juntos. As divisões por grupos também procuram preservar as proporções das classes; verificou-se a presença das cinco classes em todas as partições.

A divisão aleatória estima o desempenho em registros da mesma coleção, na qual origens e assinaturas podem aparecer no treinamento e no teste. A separação por assinatura impede a repetição exata do painel numérico entre essas amostras, mas não identifica sessões de simulação. A separação por origem avalia endereços não observados no treinamento, ainda dentro do mesmo arquivo; endereços de destino e algumas assinaturas podem coincidir. Essa avaliação não equivale a uma nova topologia, a outra execução do simulador ou a uma frota distinta de UAVs.

As partições foram definidas antes da análise dos resultados e mantidas iguais entre modelos e tratamentos de atributos. Não houve escolha de partições favoráveis nem inferência de ordem temporal a partir do identificador do fluxo.

3.3. Tratamentos de atributos

O tratamento de referência utiliza os 18 atributos numéricos originais. Foram avaliadas três razões derivadas: pacotes perdidos por pacote transmitido ($\text{LostPackets}/\text{TxPackets}$); bytes recebidos por bytes transmitidos ($\text{RxBytes}/\text{TxBytes}$); e vazão por salto ($(\text{Throughput}/\text{Kbps})/\text{AverageHopCount}$). Cada razão foi acrescentada individualmente ao painel original; também foi avaliado um tratamento que acrescenta as três razões em conjunto. As duas primeiras razões são adimensionais; a terceira é expressa em Kbps por salto. A razão entre bytes recebidos e transmitidos não representa eficiência energética.

Denominadores menores ou iguais a zero e resultados não finitos das razões geram valores ausentes; não se acrescentou uma constante ao denominador. A imputação pela mediana é ajustada exclusivamente nos dados de treinamento de cada partição e aplicada à avaliação. Uma variável derivada inteiramente ausente no treinamento é preservada e preenchida com zero. O tratamento de referência recebe o mesmo

procedimento de imputação. Não há normalização, seleção de atributos ou ajuste estatístico usando os dados de avaliação. As razões não são recortadas na análise principal.

3.4. Modelos e orçamento experimental

Random Forest [6] e XGBoost [7] foram treinados com os parâmetros fixos apresentados no Quadro 1. Não houve busca de hiperparâmetros nem escolha de modelos com base no desempenho de teste. Os ajustes utilizaram quatro núcleos de processamento; as versões do ambiente estão registradas nos materiais de reprodução.

Quadro 1. Configuração dos classificadores na avaliação preditiva.

Classificador	Configuração fixa
Random Forest [6]	200 árvores; raiz quadrada do número de atributos considerada em cada divisão; mínimo de um registro por folha; ponderação balanceada das classes.
XGBoost [7]	200 estimadores; profundidade máxima 6; taxa de aprendizado 0,1; amostragem de 80% das linhas e 80% dos atributos; objetivo probabilístico multiclasse; perda logarítmica; construção histográfica.

Fonte: configuração experimental deste estudo.

A análise principal compreendeu três protocolos, dois modelos, cinco tratamentos de atributos e cinco partições, totalizando 150 ajustes. A estabilidade foi examinada na separação por endereço de origem com três inicializações independentes para cada combinação de modelo, tratamento e partição (150 ajustes adicionais). Outros dez ajustes avaliaram, como análise de sensibilidade, o recorte da taxa de descarte de pacotes ao intervalo [0,1], mantendo os atributos originais. O recorte não foi adotado como correção dos dados.

3.5. Métricas e análise de incerteza

A medida principal é F1-macro calculado após concatenar as predições fora da amostra de todos os folds. Para cada uma das cinco classes, F1 é a média harmônica entre precisão e revocação; o F1-macro é a média não ponderada desses cinco valores. Métricas indefinidas recebem zero. Também foram obtidas precisão, revocação e F1 por classe, contagens de confusão, proporção de tráfego normal classificado como ataque e proporção de ataques classificados como normal. Essas duas últimas taxas não contabilizam confusões entre tipos de ataque como falsos alarmes ou ataques perdidos.

Cada tratamento com razões derivadas foi comparado ao tratamento de referência por diferenças pareadas. A incerteza foi estimada com 2.000 réplicas de bootstrap de grupos e intervalos percentis de 95%; a semente de reamostragem foi fixada e registrada nos materiais de reprodução. Em cada réplica, grupos são sorteados com reposição; todos os seus fluxos permanecem juntos, e o mesmo sorteio é usado nos dois tratamentos. A unidade de reamostragem é o endereço de origem na divisão aleatória e na

separação por origem, e a assinatura numérica exata na separação por assinatura. Grupos têm igual probabilidade de sorteio, mas a métrica conserva a contribuição de todos os fluxos dos grupos sorteados.

Os intervalos condicionam-se às predições fixas já obtidas. Não incorporam a incerteza de novo treinamento ou novas simulações; a dependência entre modelos treinados com partições sobrepostas permanece. Na separação por assinatura, assinaturas distintas podem pertencer à mesma origem ou execução. Partições e inicializações não foram tratadas como amostras de populações independentes. Não há ajuste de multiplicidade, teste confirmatório ou margem de equivalência predefinida. Um intervalo que inclui zero não demonstra equivalência ou ausência definitiva de efeito.


3.6. Medição da latência

Como análise secundária de custo computacional, foi medido o custo de inferência de regressão logística, MLP compacta, XGBoost e Random Forest em contêineres Linux executados no Docker Desktop/WSL2. Os modelos foram ajustados com parâmetros fixos para a finalidade exclusiva de comparar custo de inferência. A qualidade preditiva apresentada junto às latências é a estimativa de F1-macro fora da amostra obtida por separação de endereços de origem em cinco partições, na avaliação principal dos modelos de árvores. Portanto, esse F1 descreve a avaliação preditiva separada; não é uma avaliação dos modelos de benchmark ajustados em todos os registros.

Cada contêiner recebeu limite de 0,5 CPU, 512 MiB de memória e 256 processos, sem swap, com uma thread de inferência. Os modelos foram servidos individualmente pelo mesmo serviço HTTP local. A sequência das entradas foi idêntica entre os quatro modelos. Após 200 chamadas de aquecimento, foram registradas 5.000 chamadas individuais por modelo, além de 600 chamadas em lotes e 4.500 requisições para vazão em três níveis de concorrência. O tempo HTTP começa imediatamente antes do envio do corpo já serializado e termina após a leitura integral da resposta. Inclui validação e tratamento no servidor, espera por fila, processamento pelo modelo e serialização da resposta; exclui a extração do fluxo e o cálculo dos atributos. O tempo interno de predição de probabilidades é registrado separadamente.

Essa foi uma única sessão, com ordem fixa dos modelos. Percentis e consumo de memória são descritivos desta máquina e configuração. A memória máxima reportada é o máximo das amostras periódicas do monitor do contêiner, não o pico instantâneo de alocação. A medição caracteriza inferência HTTP de vetores de atributos já preparados.

Figura 1. Protocolos de validação preditiva e medição do custo de inferência. A estimativa de qualidade vem da avaliação por separação de endereços de origem; as latências vêm do benchmark local de inferência.



4. Resultados

4.1. Desempenho segundo o protocolo de avaliação

A Tabela 2 mostra o desempenho do tratamento de referência, que utiliza os 18 atributos originais. Ambos os modelos apresentam valores menores na separação por endereço de origem do que na divisão aleatória estratificada. A diferença entre esses protocolos é de aproximadamente $-0,437$ ponto percentual para RF e $-0,366$ ponto percentual para XGBoost. A diferença observada combina mudanças na população de treinamento e teste e nos padrões de sobreposição. Ela não isola causalmente vazamento por endereço ou por outro campo.

Tabela 2. F1-macro fora da amostra com os 18 atributos numéricos originais.

Protocolo de validação	Random Forest	XGBoost
Divisão aleatória estratificada	0,955051	0,956326
Separação por assinatura exata	0,953986	0,954612
Separação por endereço de origem	0,950677	0,952666

Fonte: análises do estudo com UVIDS-2025 [2].

Os valores permanecem altos na escala da métrica, mas a queda não pode ser convertida em uma garantia de transferência. A separação por assinatura e a separação por endereço de origem restringem estruturas distintas; nenhuma substitui um teste com cenários independentes. Além disso, comparar esses resultados a acurácias ou F1 de estudos com outros rótulos e pré-processamentos produziria uma ordenação inadequada.

4.2. Efeito dos atributos derivados

Na separação por endereço de origem, todos os oito intervalos condicionais que comparam cada tratamento derivado com a referência incluem zero (Tabela 3). Não há evidência consistente de ganho geral das razões propostas. Considerando os três protocolos, apenas dois dos 24 intervalos não incluem zero, ambos negativos para RF na separação por assinatura, ao acrescentar a razão entre pacotes perdidos e transmitidos, isoladamente ou junto às outras duas razões. Como as comparações são exploratórias e não ajustadas, esses casos não sustentam uma afirmação confirmatória de inferioridade.

Tabela 3. Diferenças de F1-macro na separação por endereço de origem em relação ao painel de referência com atributos originais. Valores em pontos percentuais; intervalos condicionais de 95%.

Modelo	Tratamento comparado	Diferença (pp)	Intervalo 95% (pp)
RF	Pacotes perdidos/transmitidos	-0,006	-0,087 a +0,079
RF	Bytes recebidos/transmitidos	-0,050	-0,122 a +0,022
RF	Vazão por salto	+0,041	-0,031 a +0,112
RF	Três razões em conjunto	+0,046	-0,034 a +0,131
XGBoost	Pacotes perdidos/transmitidos	-0,018	-0,084 a +0,039
XGBoost	Bytes recebidos/transmitidos	-0,044	-0,097 a +0,010
XGBoost	Vazão por salto	+0,016	-0,036 a +0,084
XGBoost	Três razões em conjunto	+0,003	-0,043 a +0,053

Fonte: análises do estudo com UVIDS-2025 [2].

A repetição com três inicializações avalia a sensibilidade à aleatoriedade dos modelos nos mesmos dados e partições. Para RF, ao acrescentar vazão por salto, a diferença média em relação à referência é +0,051 ponto percentual, com amplitude de +0,041 a +0,058. Para XGBoost, a média é +0,006 ponto percentual e a direção varia entre inicializações. Em 21 dos 24 contrastes pareados dessa repetição, o intervalo inclui

zero. A pequena magnitude e a instabilidade não autorizam escolher essa razão como vencedora geral, sobretudo sem uma margem de relevância prática estabelecida previamente.

4.3. Análise das razões derivadas

A razão entre pacotes perdidos e transmitidos é próxima de PacketDropRate em 122.148 dos 122.171 registros, sob tolerâncias absoluta 10^{-8} e relativa 10^{-5} . A correlação de Pearson é praticamente unitária. Portanto, essa variável derivada reproduz quase inteiramente um atributo existente. Acrescentar uma cópia aproximada pode alterar a seleção de variáveis pelas árvores, mas isso não representa, por si só, informação nova ou contribuição física.

A razão de vazão por salto é indefinida em 38.501 linhas, aproximadamente 31,5% dos registros. A ausência se concentra de forma desigual nas classes: ocorre em cerca de 51,3% de Normal e 48,8% de Blackhole. Assim, mudanças associadas à inclusão dessa razão podem refletir a cobertura e a imputação, além dos valores da variável. Sem uma ablação adicional que separe esses mecanismos, não atribuímos o efeito a uma medida de qualidade de enlace.

Existem 81 valores de PacketDropRate acima de um no arquivo. Os dados originais foram mantidos na análise principal. Na análise de sensibilidade, o recorte em $[0,1]$ altera o F1-macro da separação por origem em +0,043 ponto percentual para RF e +0,003 para XGBoost. Os dois intervalos condicionais incluem zero. O resultado não valida o recorte como correção, pois a fórmula exata do coletor e o tratamento dos contadores continuam sem confirmação.

4.4. Erros por classe

A Tabela 4 detalha o XGBoost no tratamento de referência, com os 18 atributos originais, na separação por endereço de origem. Blackhole apresenta revocação de 0,861241, enquanto seu F1 e o de Wormhole são inferiores aos das demais classes. Uma média global elevada pode, portanto, esconder dificuldades específicas. Essa observação é compatível com discussões anteriores sobre esses ataques [3], mas não determina sua causa física.

Tabela 4. Desempenho por classe para o XGBoost com os atributos originais na separação por endereço de origem.

Classe	Precisão	Revocação	F1
Normal Traffic	0,989284	0,991174	0,990228
Blackhole Attack	0,956568	0,861241	0,906405
Flooding Attack	0,991110	0,966491	0,978646
Sybil Attack	0,977172	0,995597	0,986299
Wormhole Attack	0,861059	0,946485	0,901753

Fonte: análises do estudo com UVIDS-2025 [2].

Há 281 fluxos de ataque classificados como normal, entre 95.999 fluxos de ataque, e 231 fluxos normais classificados como ataque, entre 26.172 fluxos normais. Esses valores correspondem a aproximadamente 0,293% de ataques perdidos e 0,883% de falsos alarmes nesse conjunto. Eles não fornecem taxas por minuto, impacto de missão ou custos de operação. A prevalência de ataques na simulação também difere de uma distribuição operacional ainda não medida.

4.5. Qualidade preditiva e custo de inferência

A Tabela 5 apresenta as estimativas fora da amostra obtidas na separação por endereço de origem, junto à latência HTTP dos respectivos modelos no contêiner. XGBoost teve o maior F1-macro observado (0,952666) e mediana HTTP de 1,107 ms. O RF ficou próximo em F1-macro (0,950677), com mediana de 5,856 ms e P95 de 51,302 ms. A MLP teve latência semelhante à regressão logística, mas maior F1-macro nesta avaliação. As diferenças pequenas entre modelos não foram testadas como comparação confirmatória, e a sessão única não sustenta um ranking estável para outros computadores.


Tabela 5. F1-macro fora da amostra na separação por endereço de origem e custo HTTP em contêiner com 0,5 CPU e 512 MiB.

Modelo	F1-macro	HTTP P50 ms	HTTP P95 ms	HTTP P99 ms	Inferência P50 ms	Memória máx. MiB
Regressão logística	0,812079	0,923	1,039	1,132	0,166	74,89
MLP compacta	0,929876	0,912	1,034	1,208	0,170	73,32
XGBoost	0,952666	1,107	1,268	8,084	0,344	82,30
Random Forest	0,950677	5,856	51,302	52,782	4,941	489,00

Fonte: estimativas de F1-macro fora da amostra e medições do benchmark local de inferência.

Os resultados mostram uma troca observada entre desempenho preditivo e custo nessa configuração. O tempo HTTP não representa o tempo total até detectar um ataque: a coleta do tráfego e o cálculo dos 18 atributos não fazem parte do benchmark. Os percentis altos e a memória próxima do limite para RF também recomendam avaliar a distribuição e a viabilidade, em vez de selecionar o candidato apenas pela mediana.

Figura 2. F1-macro fora da amostra na separação por endereço de origem e percentis de latência HTTP medidos no benchmark local. O painel de latência usa escala logarítmica; as métricas de qualidade e latência têm origens experimentais distintas.



5. Discussão

Os resultados sustentam uma contribuição metodológica delimitada: caracterizar como três protocolos e quatro tratamentos com razões derivadas alteram a classificação fechada no mesmo benchmark, em comparação com um painel de referência formado pelos atributos originais. A rastreabilidade e o relato dos resultados negativos ajudam a evitar selecionar uma configuração favorável e apresentá-la como melhoria generalizável. A contribuição depende de sua utilidade para leitores que reutilizam UVIDS-2025; ela não decorre de introduzir RF, XGBoost ou separação por origem.

A principal implicação da análise é revisar a interpretação das razões. A razão entre pacotes perdidos e transmitidos é quase redundante; a razão entre bytes recebidos e transmitidos não mede energia; e a razão de vazão por salto tem cobertura incompleta. Nomes intuitivos de atributos não substituem uma ligação verificável com o processo de coleta. Para apoiar uma interpretação de enlace ou mobilidade, seria necessário conhecer as fórmulas e janelas usadas pelo simulador e distinguir o efeito do valor derivado do efeito de sua ausência.

Os escores não estabelecem superioridade sobre a literatura. Estudos recentes usam diferentes divisões, transformações, classes e objetivos [3–5]. Uma comparação numérica justa exigiria executar métodos concorrentes no mesmo protocolo e orçamento, com pré-processamento explicitado. Isso seria uma extensão específica e não um requisito para descrever honestamente a presente avaliação interna.

6. Ameaças à validade

Validade externa: todos os testes usam um CSV simulado. Endereços retidos não representam execuções independentes ou UAVs físicos. Não há teste em tráfego real, novas topologias ou ataques desconhecidos. Uma avaliação externa exige um conjunto com semântica e rótulos compatíveis ou uma tarefa de transferência definida antes de observar os resultados.

Validade de construto: as descrições públicas não bastam para reconstruir o instante de disponibilidade de todos os atributos, as fórmulas de coleta ou o tratamento de fluxos incompletos. Estatísticas agregadas podem exigir a conclusão de um fluxo. O benchmark mede requisições HTTP locais para vetores já preparados; por isso, não estima o atraso total de detecção a partir dos pacotes de rede.

Validade interna: os parâmetros são fixos e a comparação de atributos é pareada, mas a organização por classe, as portas e os padrões da simulação podem facilitar a classificação. A separação por assinatura controla duplicação exata, não dependência entre registros semanticamente semelhantes. A separação por endereço controla essa string, não toda a estrutura de geração. As diferenças entre protocolos não constituem experimento causal de vazamento.

Validade estatística: os intervalos são exploratórios e condicionais às predições fixas. A unidade real de independência das simulações não está disponível. Múltiplas comparações não receberam correção, e três inicializações não caracterizam a incerteza de generalização. Resultados pequenos e intervalos com zero não permitem declarar equivalência entre condições.

7. Conclusão

No conjunto UVIDS-2025, Random Forest e XGBoost apresentam sensibilidade ao protocolo de avaliação, com menor F1-macro na separação por origem do que na divisão aleatória. As razões derivadas não demonstram melhoria geral consistente; a análise dos atributos revela redundância quase completa de uma delas e ausência substancial de outra. Os resultados descrevem as partições e os modelos avaliados neste conjunto de dados.

As conclusões se limitam à classificação das cinco classes conhecidas em vetores do mesmo benchmark e ao custo HTTP local medido nesta sessão. A evolução científica prioritária é identificar execuções independentes e a semântica temporal dos atributos, definir uma validação externa compatível e avaliar a inferência em plataformas embarcadas junto ao cálculo dos atributos. A versão atual pode ser avaliada como estudo crítico e reprodutível de benchmark, desde que a revisão especializada e a revista considerem essa contribuição suficiente.

Disponibilidade de dados e código

Os dados estão disponíveis no Zenodo, DOI 10.5281/zenodo.15336998, licença CC BY 4.0 [2]. Código, configurações, protocolos, predições e pacotes verificáveis foram preparados localmente. Endereço público, licença do código e DOI do arquivo de reprodução: inserir após a decisão dos autores e o depósito. Nenhum depósito público é declarado como concluído nesta versão.

Declarações dos autores

Contribuições, financiamento, conflitos de interesse e agradecimentos: preencher e aprovar pelos autores; a ausência de financiamento ou de conflitos não foi presumida. Não houve coleta com participantes humanos relatada neste estudo; eventuais exigências institucionais devem ser conferidas pelos autores.

Assistência por IA: ferramentas de IA auxiliaram a implementação, a organização da análise e a redação preliminar. Os autores devem revisar integralmente métodos, resultados, referências e texto, assumir a responsabilidade pelo conteúdo e adequar esta declaração à política da revista escolhida. Ferramentas de IA não devem figurar como autores.

Referências

- [1] Zeng, Q.; Bashir, A.; Nait-Abdesselam, F. UVIDS-2025: A Benchmark Dataset for Intrusion Detection in UAV Networks Using Machine Learning Techniques. IEEE Conference on Communications and Network Security (CNS), 2025, p. 1–9. <https://doi.org/10.1109/CNS66487.2025.11194990>.
- [2] Zeng, Q.; Bashir, A.; Nait-Abdesselam, F. UVIDS-2025. Dataset, versão 1. Zenodo, 2025. <https://doi.org/10.5281/zenodo.15336998>. Registro: <https://zenodo.org/records/15336998>. Acesso em 27 set. 2026.
- [3] Zarkadis, I.-C.; Douligieris, C. XAI and Statistical Analysis for Reliable Intrusion Detection in the UVIDS-2025 Dataset: From Tree to Hybrid and Tabular DNN Ensembles. arXiv:2605.13922v2, 2026. <https://doi.org/10.48550/arXiv.2605.13922>. Versão consultada: 10 jul. 2026; o registro informa aceitação no IEEE CITS 2026.
- [4] Aksu Demir, I. E.; Gümüş, F. Source-Rate Representations and Attention Autoencoders for Leakage-Safe Zero-Day Sybil Detection in UAV Networks. Electronics, v. 15, n. 17, artigo 3966, 2026. <https://doi.org/10.3390/electronics15173966>.
- [5] Islam, M. S.; Ahmed, F.; Ishtiaq, W.; Hossain, M. A.; Islam, M. S.; Tarek, M. M. Advanced explainable ensemble models for multi-class intrusion detection in heterogeneous drone and industrial networks. Journal on Information Security, v. 2026, artigo 14, 2026. <https://doi.org/10.1186/s13635-026-00234-w>.
- [6] Breiman, L. Random Forests. Machine Learning, v. 45, p. 5–32, 2001. <https://doi.org/10.1023/A:1010933404324>.
- [7] Chen, T.; Guestrin, C. XGBoost: A Scalable Tree Boosting System. Manuscrito dos autores, arXiv:1603.02754, 2016. <https://doi.org/10.48550/arXiv.1603.02754>.
- [8] Pedregosa, F. et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, v. 12, p. 2825–2830, 2011. <https://www.jmlr.org/papers/v12/pedregosa11a.html>.